Automated Vulnerability Triage — Documento Técnico

Repositorio: github.com/shemas2015/meli_challenge_sebastian_daza

1. Propósito de la Aplicación

Sistema de triage automatizado de vulnerabilidades de seguridad basado en un pipeline multiagente con GenAI. Recibe reportes PDF generados por scanners de seguridad, extrae los hallazgos, ejecuta validación dinámica contra la aplicación objetivo y produce un veredicto final clasificado como **TRUE_POSITIVE**, **FALSE_POSITIVE** o **INCONCLUSIVE** — con severidad y score de confianza.

---

2. Arquitectura General

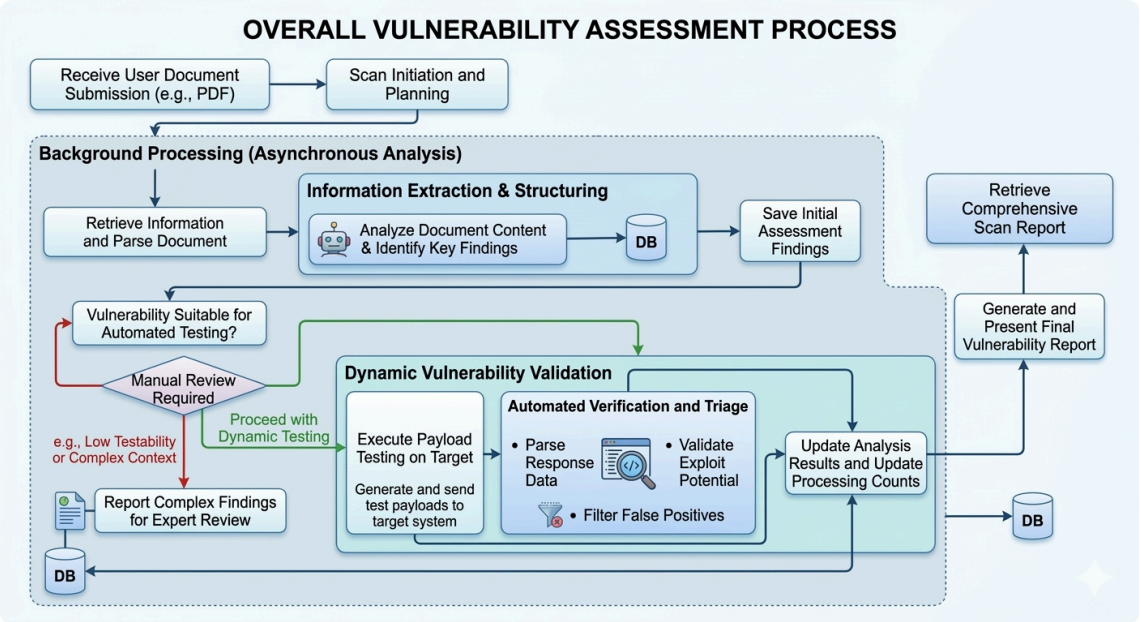

Stack tecnológico

Capa	Tecnología
Backend	Django 5.x + Django REST Framework
Agentes	CrewAI 1.x
LLM	Claude (Anthropic) / GPT-4 (OpenAI) / Gemini (Google) vía LiteLLM
Base de datos	PostgreSQL (Docker) / SQLite (local dev)
Frontend	React 18 + Vite
Infraestructura	Docker Compose (4 servicios)
Target de prueba	OWASP Juice Shop

API Docs	drf-spectacular (OpenAPI/Swagger)

Patrones de diseño aplicados

- **Repository Pattern** — capa de acceso a datos aislada en `repositories/`
- **Service Layer** — lógica de negocio en `services/`, separada de vistas y modelos
- **Factory Pattern** — `LLMProvider.get_llm()` desacopla el proveedor de LLM del resto del sistema
- **Abstract Base Class** — `BaseVulnerabilityAgent` define la interfaz de todos los agentes
- **Pipeline Pattern** — orquestación secuencial de agentes en `orchestrator.py`

---

3. Pipeline de Agentes (CrewAI)

Cada agente es una instancia de `BaseVulnerabilityAgent` que implementa `_create_agent()`, `create_task()` y `process_result()`. El orquestador los ejecuta en secuencia pasando el contexto acumulado.

```
report_data
    │
    ▼
┌──────────────────────────────────────┐
│  ParserAgent                         │
│  Estructura el reporte en campos     │
│  tipados: type, endpoint, method,    │
│  parameter, payload                  │
└──────────────────────┬───────────────┘
                       │  parsed_data
                       ▼
┌──────────────────────────────────────┐
│  DynamicValidatorAgent  (opcional)   │
│  Recibe parsed_data + resultado HTTP │
│  Evalúa: ¿el payload fue explotable? │
│  Output: exploitability, severity,   │
│  confidence                          │
└──────────────────────┬───────────────┘
                       │  dynamic_validation
                       ▼
┌──────────────────────────────────────┐
│  TriageAgent                         │
│  Sintetiza toda la evidencia         │
│  Output: validation_status, severity,│
│  confidence_score, reasoning,        │
│  recommendation                      │
└──────────────────────────────────────┘
```

Decisiones de diseño relevantes:

- `temperature=0.1` → output determinístico y consistente entre ejecuciones
- Los agentes esperan JSON envuelto en markdown code blocks; `_extract_raw()` lo parsea con regex
- El proveedor de LLM se inyecta por variable de entorno; el código de los agentes no cambia al hacer el switch

- `DynamicValidatorAgent` se saltea si `run_dynamic=False` o si no hay resultado dinámico disponible — el pipeline continúa igual

Agente especial — PDFParserAgent: Fuera del pipeline principal. Recibe texto plano del PDF y retorna un array JSON de findings. Cada finding pasa por `validate_finding()` que determina si tiene los campos mínimos para ejecutar el análisis automático (`can_auto_test`).

---

4. Modelos de Datos

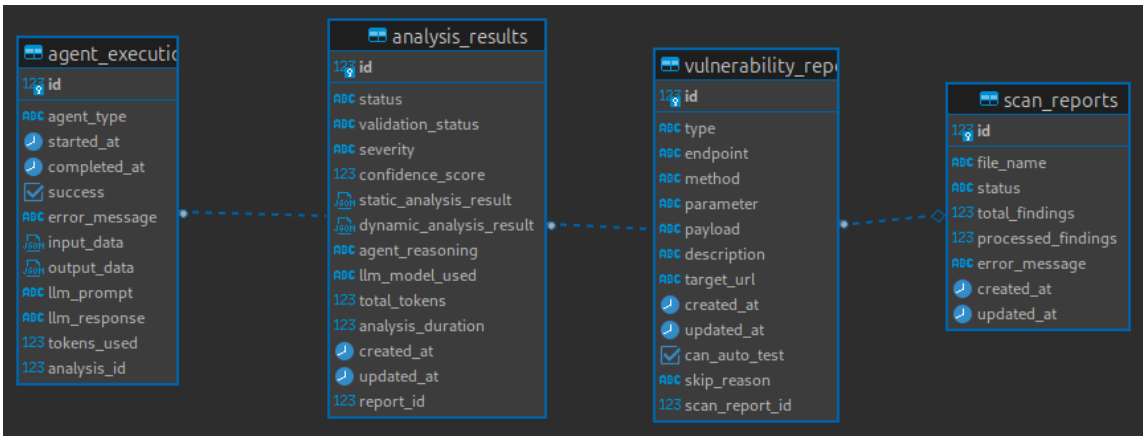

Modelo	Propósito	Campos clave
`ScanReport`	Registro del PDF subido	`status`, `total_findings`, `processed_findings`, `error_message`
`VulnerabilityReport`	Hallazgo individual	`type`, `endpoint`, `method`, `parameter`, `payload`, `target_url`, `can_auto_test`, `skip_reason`
`AnalysisResult`	Output del pipeline	`validation_status`, `severity`, `confidence_score`, `agent_reasoning`, `dynamic_analysis_result` (JSON), `analysis_duration`
`AgentExecution`	Traza de cada agente	`agent_type`, `llm_prompt`, `llm_response`, `tokens_used`, `success`, `error_message`

`AgentExecution` es clave para observabilidad: guarda el prompt completo y la respuesta de cada agente, permitiendo auditar y debuggear el razonamiento del LLM sin re-ejecutar el análisis.

Tipos de vulnerabilidad soportados: `SQL_INJECTION` , `XSS` , `PATH_TRAVERSAL` , `CSRF` , `IDOR`

Veredictos posibles: `TRUE_POSITIVE` · `FALSE_POSITIVE` · `INCONCLUSIVE`

Severidades: `CRITICAL` · `HIGH` · `MEDIUM` · `LOW` · `INFO`

---

5. API Design

Base URL: `http://localhost:8000/api/vulnerabilities/`

Método	Endpoint	Propósito	Respuesta
`POST`	`/upload`	Subir PDF	`202` + ScanReport ID
`GET`	`/uploads/`	Listar reportes	Array de ScanReports
`GET`	`/uploads/<id>/`	Estado + findings + analyses	ScanReport detallado
`GET`	`/reports/`	Listar vulnerabilidades	Array de VulnerabilityReports
`GET`	`/analyses/`	Listar resultados	Array de AnalysisResults
`GET`	`/analyses/by_status/?status=`	Filtrar por estado	Resultados filtrados
`GET`	`/analyses/by_validation_status/?validation_status=`	Filtrar por veredicto	Resultados filtrados
`GET`	`/docs/`	Swagger UI	—

---

6. Levantar el Stack Completo

Variables de entorno

Copiar el archivo de ejemplo y completar las claves necesarias:

```
cp .env.example .env
```

Editar `.env` en la raíz del proyecto:

```
# Django
DEBUG=1
SECRET_KEY=your-secret-key-here
ALLOWED_HOSTS=localhost,127.0.0.1

# Base de datos (no modificar si se usa Docker Compose)
DATABASE_URL=postgresql://postgres:postgres@db:5432/vuln_triage

# LLM — completar al menos una clave según el proveedor a usar
ANTHROPIC_API_KEY=your-anthropic-api-key
OPENAI_API_KEY=your-openai-api-key
GOOGLE_API_KEY=your-google-api-key
```

Puertos requeridos

Los siguientes puertos deben estar **libres en la máquina host** antes de levantar los servicios:

Puerto	Servicio	Descripción
`5432`	`db`	PostgreSQL

`8000`	`backend`	Django REST API
`5174`	`frontend`	React dashboard (Nginx)
`3000`	`juice-shop`	OWASP Juice Shop

Iniciar servicios

```
docker-compose up -d
docker-compose exec backend python manage.py migrate
```

Verificar que todo levantó

```
docker-compose ps
```

Detener servicios

```
docker-compose down
```

---

7. Testing

Framework: `pytest` + `pytest-django`

Estrategia: Los agentes CrewAI y las llamadas a LLM se mockean con `unittest.mock.patch`. Los tests verifican el comportamiento del sistema sin incurrir en costos de API ni dependencias externas.

Cobertura por capa:

Capa	Qué se testea
API Endpoints	Upload sin archivo → 400, archivo no-PDF → 400, PDF válido → 202, polling de status
`PDFParserAgent`	Extracción de findings, `validate_finding()` con campos completos e incompletos
`DynamicAnalyzer`	Ejecución de payloads, análisis de respuestas HTTP
`VulnerabilityAnalysisService`	Pipeline completo mockeando el orquestador
`ScanReportService`	Procesamiento async, manejo de PDF sin texto, findings con y sin auto-test
Modelos	Relaciones ORM, querysets por status/validation_status

```
# Ejecutar todos los tests dentro del contenedor backend
docker compose exec backend python manage.py test

# Test file específico
```

```
docker compose exec backend python manage.py test vulnerabilities.tests

# Con reporte de cobertura
docker compose exec backend python manage.py test --verbosity=2
```

Utilidad helper `_make_pdf_bytes()`: genera un PDF mínimo válido para tests de upload sin depender de archivos en disco.

---

8. Ejemplo de Ejecución

Las pruebas del sistema se realizaron con el reporte `input_report_v2.pdf`. El siguiente comando sube el archivo y dispara el pipeline completo:

```
curl -X POST http://localhost:8000/api/vulnerabilities/upload \
  -F "file=@input_report_v2.pdf" \
  -F "llm_provider=anthropic"
```

La respuesta inmediata (`HTTP 202`) incluye el `id` del `ScanReport`. Con ese ID se puede consultar el progreso:

```
curl http://localhost:8000/api/vulnerabilities/upload/<id>/
```

---

9. Frontend

Interfaz web construida en **React 18 + Vite**, servida en el puerto `5174`. Se comunica con el backend vía REST y permite operar el sistema completo sin usar la línea de comandos.

Pantalla principal — listado de scans

Muestra todos los reportes PDF procesados con su estado (`PENDING`, `PROCESSING`, `COMPLETED`, `FAILED`), la cantidad de findings encontrados y los resultados de cada análisis de vulnerabilidad.

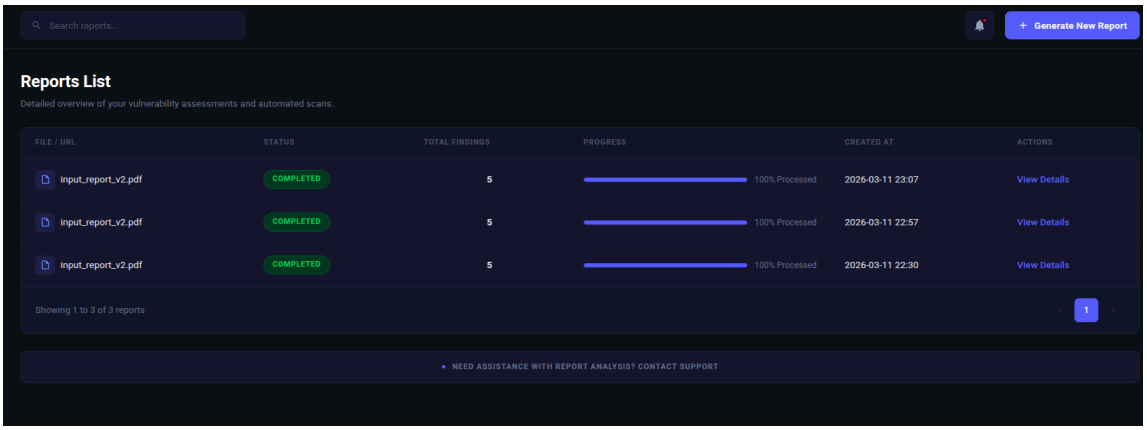

Cargar nuevo reporte

Formulario para subir un PDF de scanner. Una vez enviado, el sistema procesa el reporte en background y actualiza el estado en tiempo real.

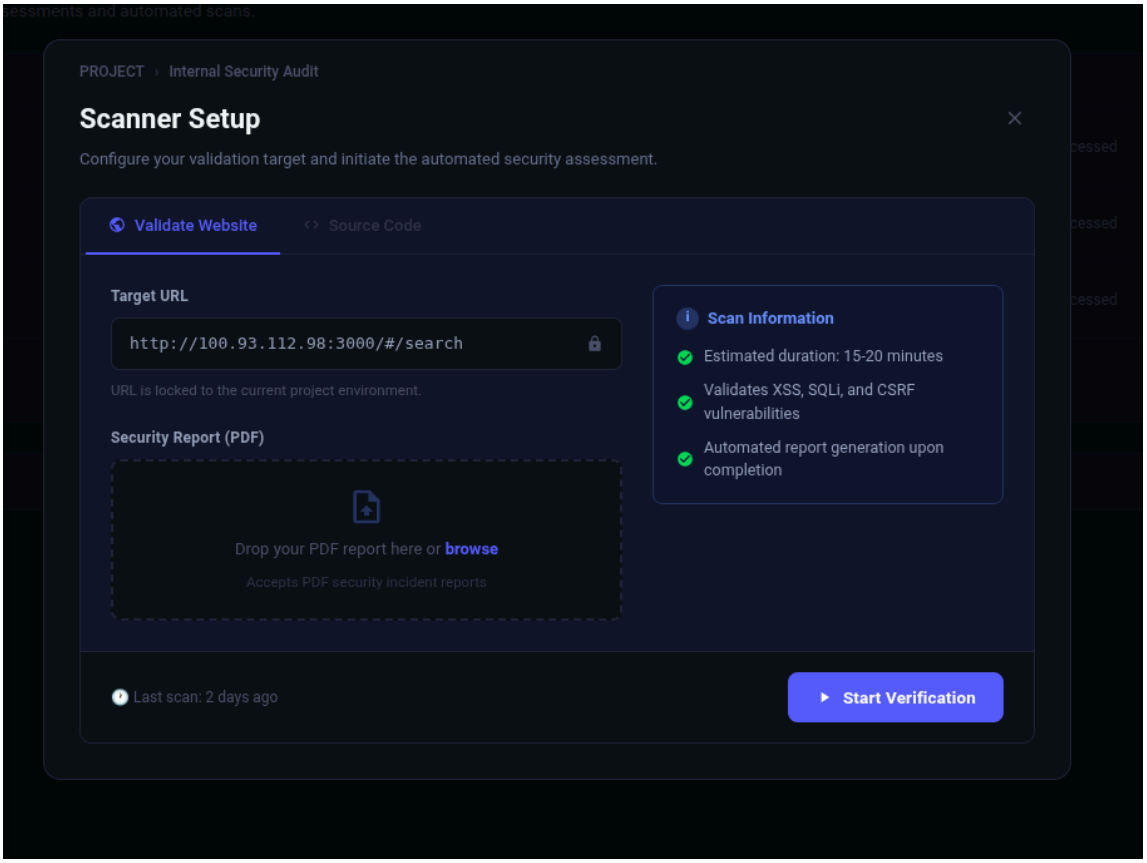

Detalle de un scan

Vista expandida de un scan individual. Muestra cada vulnerabilidad encontrada con su veredicto (`TRUE_POSITIVE` , `FALSE_POSITIVE` , `INCONCLUSIVE`), severidad, score de confianza y el razonamiento completo del agente de triage.

SCAN REPORT #3

input_report_v2.pdf

STATUS	FINDINGS	PROGRESS
COMPLETED	5	5/5

▸ AGENT EXECUTIONS (3)

CSRF TRUE POSITIVE MEDIUM

ENDPOINT	`POST /profile`
PARAMETER	`username`
PAYLOAD	`{"login_url": "/rest/user/login", "credentials": {"email": "admin@juice-sh.op", "password": "admin123"}, "form_data": "username=CSRF_DEMO"}`
DESCRIPTION	The profile update endpoint accepts POST requests using a session cookie (token) without any CSRF token validation. An attacker can trick an authenticated victim into changing their username by embedding a forged cross-origin form POST in a malicious page. The browser automatically sends the session cookie, and the server processes the request without verifying its origin.
CONFIDENCE	92%
REASONING	The dynamic validation evidence conclusively confirms a Cross-Site Request Forgery (CSRF) vulnerability on the POST /profile endpoint. The evidence is clear, technically sound, and demonstrates actual state change without CSRF protection. The following factors establish this as a confirmed true positive: 1. **Confirmed State Change Without CSRF Token**: The most definitive evidence is that a POST request to /profile with username='CSRF_DEMO' — submitted without any CSRF token — returned HTTP 200 and the server accepted, stored, and reflected the new username value in two locations in the response body: in the display paragraph ('\CSRF_DEMO') and in the form input field (value='CSRF_DEMO'). This proves the server performs no CSRF token validation before processing state-changing requests. 2. **Absence of All Standard CSRF Mitigations**: The evidence documents a complete absence of CSRF protections across multiple layers: (a) No hidden CSRF token field in the HTML form — a properly protected form would include '<input type="hidden"

Stack: Django 5 · CrewAI 1.x · LiteLLM · PostgreSQL · React 18 · Docker